



Veröffentlichung von Forschungsdaten

Prof. Dr.-Ing Stefan Gudenkauf

Ein Leitfaden mit Markdown für GitHub und Zenodo

Dieses Dokument wurde gefördert durch das Niedersächsische Ministerium für Wissenschaft und Kultur mit Mitteln aus dem Programm zukunft.niedersachsen der VolkswagenStiftung. Projekt Data Driven Health (DEAL)

v2.0.0

Institut für Wirtschaftsinformatik (IfW)
Fachbereich Management, Information, Technologie
Jade Hochschule

6. Mai 2026

Inhaltsverzeichnis

Abstract	1
Nutzungsbedingungen	1
Werkseintrag	1
1 Der Weg zur Datenveröffentlichung	3
1.1 Daten vorbereiten	4
1.2 GitHub-Repository einrichten	5
1.3 Zenodo mit GitHub verbinden	6
1.4 Daten auf Zenodo veröffentlichen	7
1.5 Veröffentlichung bekannt machen	7
2 Ein einfacher Datenmanagementplan	9
3 FAIR-Prinzipien berücksichtigen	11
3.1 Findable: DOI, Metadaten und Suchmaschinenoptimierung	11
3.1.1 DOI und Metadaten ergänzen	11
3.1.2 Suchmaschinen unterstützen	12
3.2 Accessible: Langfristige Zugänglichkeit sicherstellen	13
3.3 Interoperable: Datenformate und Standards beschreiben	13
3.4 Reusable: Dokumentation und Lizenzierung beschreiben	13
3.5 README-Datei und Zugriff auf Metadaten	14
4 Semantic Versioning für Forschungsdaten	15
4.1 Übertragung von SemVer auf Forschungsdaten	15
4.2 Vorgehen für die Versionierung	15
5 Der Umgang mit Gesundheitsdaten	17
5.1 Datenschutz und Ethik	17
5.2 Anonymisierung und Pseudonymisierung	18
5.3 Kontrollierter Zugriff und Verteilung	18
5.4 Verwendung standardisierter Terminologien	19
5.5 Interoperabilität	19
5.6 Versionierung und Nachvollziehbarkeit	20
5.7 Dokumentation der Datenerhebung und der einzelnen Verarbeitungsschritte	20
6 Zusammenfassung	21
6.1 Anleitung zur Datenveröffentlichung	21
6.2 Datenmanagementplan (DMP) erstellen und pflegen	21
6.3 Versionierung für Forschungsdaten anpassen	21
6.4 Umgang mit Gesundheitsdaten	22
7 Anhang	23
7.1 README-Datei für GitHub-Repository: README.md	23
7.2 Datenmanagementplan: DMP.md	23
7.3 Datenmanagementplan für deutschsprachige Gesundheitsprojekte: DMP-health.md	26

Inhaltsverzeichnis

7.4	Informierte Einwilligung: IC.md	27
7.5	Data Use Agreement: DUA.md	28
7.6	Checkliste der FAIR-Prinzipien: FAIR.md	30
7.7	Beispiel für ein Changelog: CHANGELOG.md	31
7.8	Beispiele für Metadaten mit Zenodo	31
7.9	Verwendete Softwarewerkzeuge	33

Literaturverzeichnis	35
-----------------------------	-----------

Abbildungsverzeichnis

1.1	GitHub Desktop im Überblick.	5
1.2	GitHub-Integration in Zenodo.	6
1.3	Hauptseite eines Repositorys auf der GitHub Webseite.	7
1.4	Erstellen eines Release in einem GitHub-Repository.	8
3.1	Export von Metadaten aus Zenodo.	12
5.1	Modularisiertes Datenschutzkonzept gemäß REF (eigene Darstellung).	19
5.2	Beispielrealisierung einer Änderungshistorie als UML-Klassendiagramm. Die Klassen könne als Tabellen verstanden werden, die Attribute als Spaltenbezeichnungen in den Tabellen.	20

Tabellenverzeichnis

1.1	Werkzeuge zur Veröffentlichung von Forschungsdaten.	3
1.2	Ausgewählte Empfehlungen zur Dateibenennung.	4
4.1	Beispiel zur Erhöhung der Versionskennung.	16

Abstract

Dieses Dokument richtet sich an Sie als Forschende/r einer Einrichtung mit begrenzten Mitteln für Forschungsdatenmanagement. Entweder stehen Sie direkt vor der Veröffentlichung eines neuen Datensatzes oder Sie möchten die Daten zu einer bereits bestehenden Veröffentlichung nachträglich zugänglich machen. Vielleicht sind sie auch im Rahmen einer Förderung durch Dritte dazu angehalten, Ihre Daten zu veröffentlichen. Dieses Dokument möchte Ihnen helfen, dieses Vorhaben mit möglichst geringem persönlichen Aufwand professionell umzusetzen.

This document is intended for researchers at institutions with limited resources for research data management. You may be about to publish a new dataset or looking to make data from an existing publication publicly accessible. Perhaps you are required to share your data as part of a third-party funding agreement. This document aims to help you achieve this professionally with minimal personal effort.

Keywords: research data management, data management plan, semantic versioning, fair principles, rdm tools, health data

Nutzungsbedingungen

Dieses Werk von [Stefan Gudenkauf](#) steht unter der Lizenz [CC BY-SA 4.0](#).

Werkseintrag

[BibTex](#)-Eintrag:

```
@techreport{gudenkauf_veroeffentlichung_2026,  
  address = {Wilhelmshaven},  
  title = {Veröffentlichung von {Forschungsdaten}: {Ein} {Leitfaden} mit  
    ↪ {Markdown} für {GitHub} und {Zenodo}},  
  copyright = {CC BY-SA 4.0},  
  url = {https://github.com/sgudenkauf/quarto-simple-rdm-tutorial},  
  doi = {https://doi.org/10.5281/zenodo.14840823},  
  language = {Deutsch},  
  institution = {Institut für Wirtschaftsinformatik (IfW), Jade  
    ↪ Hochschule},  
  author = {Gudenkauf, Stefan},  
  month = may,  
  year = {2026},  
}
```

Bitte geben Sie als Quellenangabe folgende Referenz an:

Gudenkauf, S. (2026). Veröffentlichung von Forschungsdaten: Ein Leitfaden mit Markdown für GitHub und Zenodo. Institut für Wirtschaftsinformatik (IfW), Jade Hochschule. <https://doi.org/10.5281/zenodo.14840823>

1 Der Weg zur Datenveröffentlichung

Dieses Dokument richtet sich an Sie als Forschende/r einer Einrichtung mit begrenzten Mitteln für Forschungsdatenmanagement. Es soll Ihnen helfen, dieses Vorhaben mit möglichst geringem persönlichen Aufwand umzusetzen.¹ lautet die Zieldefinition: Verringerung (Zweck) des persönlichen Aufwands (Problem) zu Management von Forschungsdaten (Prozess) aus der Sicht einzelner Forschenden.]

Bevor wir die einzelnen Schritte zur Veröffentlichung von Forschungsdaten durchgehen, benennen wir die **grundlegenden Fragen**:

1. Wo speichere ich meine Daten?
2. Wie verwalte ich neue Versionen meines Datensatzes?
3. Wie mache ich meinen Datensatz öffentlich und referenzierbar?
4. Wie beschreibe ich meinen Datensatz und dessen Metadaten sinnvoll?
5. Wie handhabe ich die FAIR-Prinzipien um?

Die Wahl der **Werkzeuge** beeinflusst sehr, wie aufwendig die Beantwortung dieser Fragen ist. Für diese Anleitung haben wir die Auswahl nach folgenden Kriterien getroffen:

1. So wenig Werkzeuge wie möglich
2. Robustheit und langfristige Verfügbarkeit
3. Hohe fachübergreifende Verbreitung
4. Keine zwingenden Abhängigkeiten von Verwaltungsstrukturen innerhalb der eigenen Einrichtung

Tabelle 1.1 beschreibt die Werkzeuge, die wir zur Veröffentlichung von Forschungsdaten verwenden werden. Schauen Sie sich ruhig schon einmal an, bevor wir mit den weiteren Schritten fortfahren.

Tabelle 1.1: Werkzeuge zur Veröffentlichung von Forschungsdaten.

Werkzeug	Beschreibung	Fragen
GitHub	Internetdienst zum kollaborativen Erstellen, Speichern, Verwalten und Teilen von Code. Basiert auf dem kostenlosen und quelloffenen verteilten Versionskontrollsystem Git . Unterstützt die Versionierung mittels Releases.	1, 2
Zenodo	Offene europäische Plattform zur Veröffentlichung wissenschaftlicher Ergebnisse. Jede Einreichung erhält einen dauerhaften digitalen Objektbezeichner (DOI, siehe auch DOI Handbook (2023)).	3

¹Gem. Goal Question Metric (GQM) nach Basili u. a. (1994)

Werkzeug	Beschreibung	Fragen
Markdown	Stark vereinfachte Auszeichnungssprache für die Erstellung von formatierten Text. Kann leicht in verschiedene Zielformate übersetzt werden.	4, 5

1.1 Daten vorbereiten

1. Bereiten Sie Ihre Daten auf:

- Verwenden Sie eine strukturierte, verständliche Dateibenennung. Es empfehlen sich die Best Practices der MIT Libraries, siehe Malinowski (2020). In Tabelle 1.2 stellen wir Ihnen ausgewählte Empfehlungen vor.
- Entfernen Sie sensible oder personenbezogene Daten.
- Dokumentieren Sie Ihr Vorgehen zur Datenerhebung und -aufbereitung in einer separaten Datei, z. B. README.md oder metadata.txt.

2. Erstellen Sie eine geeignete Ordnerstruktur:

- Erstellen Sie ein Hauptverzeichnis mit klar strukturierten Unterordnern, z. B. /raw_data, /processed_data, /scripts.

Hinweis

In Kapitel 7.1 finden Sie das Beispiel einer README-Datei in einfachem Markdown-Textformat. Es beinhaltet Textbausteine, die für die Ablage in einem GitHub-Repository geeignet sind.

Tabelle 1.2: Ausgewählte Empfehlungen zur Dateibenennung.

Thema	Empfehlungen
Dateinamen	nicht mehr als 32 Zeichen
Trennzeichen	nur Unterstrich _ und camelCase als Trenner, z. B. Handout_dateibenennung.pdf keine Leerzeichen
Sonderzeichen	keine Punkte außer direkt vor der Dateiendung keine sonstigen Sonderzeichen wie z. B. &, *, %, #, ;, !, @, ~, ', [,], {, }, ?, <, >
Datumsangaben	möglichst konsistent, um das Suchen und Sortieren zu erleichtern YYYYMMDD (Jahr, Monat, Tag) ist ein sehr gutes Format, z. B. 20240828_Protokoll.pdf
Nummerierungen	führende Nummern zur Abbildung fester Sequenzen Sequenzen von 1 bis 10: 01_bis 10_ Sequenzen von 1 bis 100: 001_bis 100_

1.2 GitHub-Repository einrichten

GitHub basiert auf dem kostenlosen und quelloffenen Versionskontrollsystem [Git](#). Grundsätzlich können Sie auf der Kommandozeile Ihres Computers mit Git-Befehlen arbeiten, um Ihren Datensatz in GitHub zu pflegen (z. B. `git init`, `git add`, `git commit`). Dasselbe können Sie aber auch mit der leicht zu bedienenden Desktop-Anwendung [GitHub Desktop](#) erreichen.

Im Rahmen dieser Anleitung empfehlen und verwenden wir GitHub Desktop (Abbildung 1.1). Einen guten Einstieg in die Arbeit mit GitHub Desktop finden Sie in der offiziellen [GitHub-Dokumentation](#).




Abbildung 1.1: GitHub Desktop im Überblick.

1. GitHub-Konto erstellen:

- Registrieren Sie sich auf [GitHub](#).
- Nach der Registrierung können Sie sich auf GitHub anmelden.
- Installieren Sie [GitHub Desktop](#).

2. Neues Repository erstellen:

- Melden Sie sich auf [GitHub](#) an und erstellen Sie ein neues öffentliches Repository.
- Alternativ können Sie das Repository auch mit GitHub Desktop erstellen: `File > New repository...` (Menüleiste oben links in [Abbildung 1.1](#))
- Benennen Sie das Repository sinnvoll und passend zu `README.md` (z. B. `projectname-dataset`).

1 Der Weg zur Datenveröffentlichung

- Ist das Repository erstellt, gleicht GitHub Desktop das lokale Repository-Verzeichnis auf Ihrem Rechner mit dem öffentlichen Repository auf GitHub ab. Änderungen, die Sie am lokalen Ordner vornehmen, können hinzugefügt (`git add`), festgeschrieben (`git commit`) und anschließend in das öffentliche Repository übertragen werden (`git push`).

3. Daten in das Repository übertragen:

- Legen Sie Ihre Daten und die README-Datei in das lokale Repository-Verzeichnis auf Ihrem Rechner.
- Geben Sie Ihre Änderungen am lokalen Repository-Verzeichnis an das öffentliche Repository auf GitHub weiter: `Commit to main` (unten links in Abbildung 1.1), dann `Push origin` (erscheint nach dem Commit oben rechts statt `Fetch origin` in Abbildung 1.1)
- Arbeiten Sie mit mehreren Personen gemeinsam am Repository, sollten Sie vor jedem Commit zunächst den aktuellen Stand einholen und mit Ihren Änderungen vergleichen: `Fetch origin` (oben rechts in Abbildung 1.1)

1.3 Zenodo mit GitHub verbinden

1. Zenodo-Konto erstellen:

- Registrieren Sie sich auf [Zenodo.org](https://zenodo.org). Nach der Registrierung können Sie sich z. B. mit Ihrer [ORCID ID](#) anmelden.

2. GitHub-Integration aktivieren:

- Gehen Sie nach der Anmeldung zu “Settings” und verbinden Sie Ihr GitHub-Konto mit Zenodo: `My account > GitHub` (Abbildung 1.2)
- Wählen Sie das Repository aus, das mit Zenodo veröffentlicht werden soll.




Abbildung 1.2: GitHub-Integration in Zenodo.

1.4 Daten auf Zenodo veröffentlichen

1. GitHub-Release erstellen:

- Melden Sie sich auf der GitHub-Webseite an und öffnen Sie die Hauptseite Ihres Repositories.²
- Erstellen Sie ein Release im GitHub-Repository: Releases > Draft a new release (unten rechts in Abbildung 1.3)




Abbildung 1.3: Hauptseite eines Repositories auf der GitHub Webseite.

- Geben Sie als Tag eine passende Versionsnummer (z. B. v1.0.0) und eine kurze Beschreibung für das Release an (Abbildung 1.4).
- Eine detaillierte Anleitung zum Erstellen eines Releases finden Sie in der [GitHub-Dokumentation](#).

2. Automatische Zenodo-DOI erstellen:

- Zenodo generiert automatisch einen DOI für das Release.
- Fügen Sie den DOI zur README-Datei hinzu.

1.5 Veröffentlichung bekannt machen

- Verweisen Sie im Paper auf die DOI des Datensatzes.
- Teilen Sie den Zenodo-Link und den DOI mit Ihrem Netzwerk.

²GitHub Desktop unterstützt das Erstellen von Releases momentan nicht.

1 Der Weg zur Datenveröffentlichung




Abbildung 1.4: Erstellen eines Release in einem GitHub-Repository.

2 Ein einfacher Datenmanagementplan

Ein Datenmanagementplan (DMP) beschreibt, wie Daten gesammelt, gespeichert, dokumentiert und geteilt werden sollen. Fördergeber erwarten von Ihnen zunehmend die Erstellung und Fortführung solcher Pläne im Rahmen der Beantragung und Durchführung Ihrer Forschungsprojekte. Inhaltlich sollten folgende Punkte beschrieben werden:

1. Projektbeschreibung und Zielsetzung
2. Arten und Umfang der Daten
3. Speicherung und Sicherung
4. Dokumentation und Metadaten
5. Veröffentlichung und Nachnutzung
6. Verantwortlichkeiten und Ressourcen
7. Ethik und Datenschutz
8. Aktualisierungen des Plans

Speichern Sie die eigentlichen Forschungsdaten in **offenen, maschinenlesbaren Formaten** wie CSV (für Tabellen) oder JSON (für strukturierte Daten), um Interoperabilität und Wiederverwendbarkeit sicherzustellen. Mehr dazu finden Sie in Kapitel 3.

Hinweis

In Kapitel 7.2 finden Sie das Beispiel eines Datenmanagementplans in einfachem [Markdown-Textformat](#). Er beinhaltet Textbausteine, die für die Ablage in einem GitHub-Repository geeignet sind.

3 FAIR-Prinzipien berücksichtigen

Die FAIR-Prinzipien sind Richtlinien für die Speicherung und Veröffentlichung wissenschaftlicher Daten. Einen guten Einstieg bieten „Data models to GO-FAIR“ (2017) und Wilkinson u. a. (2016).

Daten sollen auffindbar, zugänglich, interoperabel und wiederverwertbar sein. Diese vier Eigenschaften werden häufig auf 15 [FAIR-Prinzipien](#) abgebildet. Auf der Ebene der vier grundlegenden Eigenschaften bietet Ihnen dieses Kapitel aber einen ersten Einstieg.

Hinweis

In Kapitel [7.6](#) finden Sie eine Checkliste der 15 FAIR-Prinzipien in einfachem [Markdown-Textformat](#).

3.1 Findable: DOI, Metadaten und Suchmaschinenoptimierung

Unsere Forschungsdaten und Softwareprojekte erstellen und pflegen wir häufig mit speziellen Softwarewerkzeugen. Dabei generieren wir schon vor der Veröffentlichung fortwährend Metadaten. Diese sind üblicherweise eher technischer Natur und gern in werkzeugspezifischen Konfigurationsdateien verstreut.

- Dann haben wir für jedes mit [GitHub](#) verwaltete Projekt eine README-Datei erstellt, die weitere Informationen über unser Projekt enthält (Kapitel [1](#)).
- Dann haben wir unsere Projekte in [Zenodo](#) integriert und müssen auch dort Informationen ergänzen (Kapitel [1](#)).

Letztendlich wollen wir, dass unsere Forschungsdaten oder Softwareprojekte als Produkte eines Forschungsprozesses gefunden werden können. Dazu müssen wir sicher stellen, dass **produktrelevante Metadaten** in einem **standardisierten Format** vorliegen. Das ist mit Zenodo aber leichter, als es zunächst den Anschein hat, die Arbeit ist im Grunde schon erledigt.

3.1.1 DOI und Metadaten ergänzen

Prüfen Sie folgende Punkte, um die Auffindbarkeit der Daten zu verbessern:

1. Stellen Sie sicher, dass Metadaten in einem standardisierten Format beschrieben werden. Bekannte Formate sind z. B. [DataCite](#) oder [Dublin Core](#).
2. Machen Sie Angaben zu üblichen Schlagwörtern und standardisierten Vokabularen zu Ihrem Fachgebiet.
3. Dokumentieren Sie im Datenmanagementplan die Art der Vergabe einer DOI, sowie das verwendete Format oder den Standard, nach dem Metadaten kodiert sind (@#sec-dmp).

Zenodo übernimmt für Sie neben der Vergabe eines digitalen Objektbezeichners (DOI, siehe auch DOI Handbook (2023)) auch die Generierung von standardisierten Metadaten. Data Cite und Dublin Core können dann direkt aus Zenodo abgefragt werden, beispielsweise über die Exportfunktion (unten rechts in Abbildung [3.1](#)).

3 FAIR-Prinzipien berücksichtigen




Abbildung 3.1: Export von Metadaten aus Zenodo.

i Hinweis

In Kapitel 7.8 finden Sie die Metadaten zu diesem Dokument in den Formaten [DataCite JSON](#) und [Dublin Core XML](#).

Ergänzen Sie bei Bedarf im DMP:

****Metadatenformat**:**

- [z. B. [DataCite](#), [Dublin Core](#)]

****Beschreibung der Daten**:**

- Jede Datei wird durch eine README-Datei dokumentiert, die Informationen
↪ über:
 - Den Inhalt
 - Die Erhebungsmethodik
 - Verwendete Software oder Tools enthält.
- Schlagwörter: [[Themenrelevante Begriffe](#), z. B. "[Machine Learning](#)",
↪ "[Umweltdaten](#)"]

****DOI-Zuweisung**:**

- Die Veröffentlichung erfolgt mit einem DOI über Zenodo.

3.1.2 Suchmaschinen unterstützen

- GitHub-Projekte werden in der Regel von GitHub automatisch indexiert, so dass sie besser gefunden werden können.
- Zusätzlich sollten Sie keine unnötigen [.gitignore-Einstellungen](#) in GitHub verwenden.

3.2 Accessible: Langfristige Zugänglichkeit sicherstellen

- Ergänzen Sie im Datenmanagementplan explizit Angaben zur langfristigen Speicherung über Zenodo und dass die Daten öffentlich zugänglich sind ([Open Access](#)).
- Zeitliche Einschränkungen des Zugriffs können über die den so genannten [Embargo-Status](#) in Zenodo geregelt werden.

Ergänzen Sie bei Bedarf im DMP:

****Zugänglichkeit**:**

- Die Daten sind über Zenodo öffentlich zugänglich ([Open Access](#)).
- Der DOI garantiert die dauerhafte Verfügbarkeit.
- Einschränkungen: Einschränkungen des Zugriffs werden über Embargo-Status
→ Optionen von Zenodo geregelt.

3.3 Interoperable: Datenformate und Standards beschreiben

- Verwenden Sie für Ihre Daten Dateiformate, die eine möglichst einfache maschinelle Verarbeitung erlauben.
 - Es bieten sich offene Formate wie z. B. CSV gemäß Hausenblas u. a. (2014) und JSON gemäß Charollais an.
 - Verzichten Sie auf proprietäre Formate wie z. B. Microsoft Excel (.xlsx-Dateien).
- Nennen Sie die verwendeten Standards für Daten und Metadaten wie z. B. [DataCite](#), [Dublin Core](#) oder [JSON-Schema](#).
- Nennen Sie Ontologien oder kontrollierte Vokabulare zur Standardisierung von Fachbegriffen, z. B. [MeSH](#), [AGRO-VOC](#).

Ergänzen Sie bei Bedarf im DMP:

****Interoperabilität**:**

- Daten werden in offenen Formaten gespeichert (siehe Abschnitt 2, Arten und
→ Umfang der Daten)
- Metadaten-Standards: DataCite für Beschreibung und DOI-Referenzierung
- Ontologien oder kontrollierte Vokabulare zur Standardisierung von
→ Begriffen: Verwendung von [[z. B. MeSH](#), [AGROVOC](#)]

3.4 Reusable: Dokumentation und Lizenzierung beschreiben

Ohne Angabe einer Lizenz können Ihre Daten nicht weiterverwendet werden. Weit verbreitet und üblich sind die Lizenz [CC-BY 4.0](#) für Dokumente und die [MIT-Lizenz](#) für ausführbaren Programmcode und Softwareprojekte.

Als recht freizügige Lizenz bietet die MIT-Lizenz ein geringes Risiko im Zusammenspiel mit anderen Lizenzen. Beispielsweise erlaubt sie die Wiederverwendung von Code in proprietärer Software. Creative-Commons-(CC)-Lizenzen sind dagegen nicht für die Nutzung in Software oder Hardware empfohlen (Bals (2024)).

Da Veröffentlichungen von Forschungsdaten häufig auch ausführbaren Code wie z.B. Python-Skripte beinhalten, bevorzugen wir im Zweifelsfall die MIT-Lizenz.

Ergänzen Sie bei Bedarf im DMP:

3 FAIR-Prinzipien berücksichtigen

****Wiederverwendbarkeit:****

- Lizenz: [z. B. MIT, erlaubt die Nachnutzung auch in proprietärer Software
↪ unter der Bedingung der Namensnennung]
- Vollständige Dokumentation der Daten: [Methoden, Kontext, verwendete
↪ Software wie z. B. Python-Skripte mit spezifischen Bibliotheksversionen]
- Anleitungen für die Nachnutzung: [z. B. siehe README-Datei]

3.5 README-Datei und Zugriff auf Metadaten

Falls Metadaten generiert werden, können Sie darauf auch in der README-Datei verweisen. Verwenden Sie Zenodo, genügt ein Verweis auf den DOI, der auf Zenodo verweist.

- Menschliche Nutzer können standardisierte Metadaten aus Zenodo exportieren (Abbildung 3.1).
- Der softwaretechnische Zugriff auf Metadaten kann mittels Python-Skripte über die [Zenodo-API](#) realisiert werden.

Ergänzen Sie bei Bedarf in der README-Datei:

Metadata

The dataset is described using the DataCite metadata schema. Key elements

↪ include:

- ****Title****: Title of the dataset.
- ****Author(s)****: Name(s) of the contributors.
- ****Keywords****: Relevant keywords for discoverability.
- ****Description****: Detailed dataset description, including methodology and
↪ tools.
- ****License****: MIT
- ****DOI****: [[Zenodo DOI link](#)].

4 Semantic Versioning für Forschungsdaten

Semantic Versioning ([SemVer](#)) ist ein Standard für die Vergabe von Versionsnummern bei der Entwicklung von Software. Es besteht aus drei Komponenten: MAJOR . MINOR . PATCH. Eine typische Versionsnummer nach SemVer kann z.B. so aussehen: v1 . 0 . 1.

Hinweis

In Kapitel [7.7](#) finden Sie ein Beispiel für ein Changelog in einfachem [Markdown-Textformat](#).

4.1 Übertragung von SemVer auf Forschungsdaten

SemVer eignet sich aus unserer Sicht auch sehr gut für die Veröffentlichung von Forschungsdaten. Hierzu müssen wir die Semantik der Komponenten geringfügig anpassen:

- MAJOR: Erhöhen bei grundlegenden Änderungen, die die Abwärtskompatibilität der Forschungsdaten brechen (z. B. neue Variablenstruktur, neue Datensätze).
- MINOR: Erhöhen bei Hinzufügungen, die abwärtskompatibel sind (z. B. neue Datenpunkte, zusätzliche Dokumentation)
- PATCH: Erhöhen bei kleinen Korrekturen, die abwärtskompatibel sind (z. B. Fehlerkorrekturen in den Daten).

4.2 Vorgehen für die Versionierung

1. **Initiale Version:** Starten Sie mit v1 . 0 . 0 für das erste in Zenodo integrierte GitHub-Release (siehe Kapitel [1](#)).¹
2. **Dokumentation von Änderungen:**
 - Dokumentieren Sie sämtliche Änderungen zwischen den Versionen in einem Changelog, z. B. CHANGE-LOG . md.
 - Erhöhen Sie die Versionskennung gemäß SemVer, siehe Tabelle [4.1](#).
3. **Release-Management:**
 - Verwenden Sie [GitHub-Releases](#), um neue Versionen zu kennzeichnen.
 - Die Zenodo-Integration erzeugt automatisch neue DOIs für jede Version.

¹Für Arbeitsversionen können Sie vor der ersten Veröffentlichung mit Zenodo-Integration Kennungen kleiner als v1 . 0 . 0 vergeben. Beginnen Sie z.B. mit der Kennung v0 . 0 . 1.

Tabelle 4.1: Beispiel zur Erhöhung der Versionskennung.

Alte Kennung	Änderung	Neue Kennung
v1.0.2	PATCH	v1.0.3
v1.0.3	MINOR	v1.1.0
v1.1.0	PATCH	v1.1.1
v1.1.1	MAJOR	v2.0.0

5 Der Umgang mit Gesundheitsdaten

Die Datenschutzgrundverordnung (DSGVO) definiert Gesundheitsdaten als “personenbezogene Daten, die sich auf die körperliche oder geistige Gesundheit einer natürlichen Person, einschließlich der Erbringung von Gesundheitsdienstleistungen, beziehen und aus denen Informationen über deren Gesundheitszustand hervorgehen” (§ 46 Abs. 13 DSGVO). Sie gelten als besonders sensibel. Beispielsweise erlaubt [Art. 9 DSGVO](#) deren Verarbeitung nur in ausgewählten Fällen. Die Dokumentation solcher Daten ist dabei genauso wichtig wie die Daten selbst. Dadurch ergeben sich besondere Anforderungen an die Handhabung von Gesundheitsdaten in der Forschung:

- Zentrale Bedeutung von Datenschutz und Ethik
- Anonymisierung und Pseudonymisierung
- Kontrollierter Zugriff und Verteilung
- Verwendung standardisierter Terminologien
- Interoperabilität
- Versionierung und Nachvollziehbarkeit
- Dokumentation der Datenerhebung und der einzelnen Verarbeitungsschritte

Als Ideal kann die Faustregel “So offen wie möglich, so geschlossen wie nötig” gesehen werden.

Hinweis

Als Dachorganisation der medizinischen Verbundforschung in Deutschland stellt die TMF e.V. in ihrer Schriftenreihe diverse Konzepte, Leitfäden und Rechtsgutachten zum Umgang mit Gesundheitsdaten bereit. Die [Bände der TMF-Schriftenreihe](#) sind als Open-Access-Versionen frei verfügbar.

Hinweis

In Kapitel [7.3](#) finden Sie das Beispiel eines Datenmanagementplans speziell für für deutschsprachige Gesundheitsprojekte in einfachem [Markdown-Textformat](#).

5.1 Datenschutz und Ethik

Vor dem Projektstart sollte geklärt werden:

1. Liegt ein [Ethikvotum](#) vor?¹
2. Gibt es eine informierte Einwilligung (engl. informed consent)
3. Welche Art der Verarbeitung und Datennachnutzung umfasst die informierte Einwilligung?²

¹Wann ist ein Ethikvotum überhaupt notwendig? Der Arbeitskreis Medizinischer Ethik-Kommissionen in der Bundesrepublik Deutschland e.V. stellt eine übersichtliche Entscheidungshilfe parat, siehe <https://www.akek.de/einreichung-von-forschungsvorhaben/>

²Siehe z. B. https://www.pedocs.de/volltexte/2022/22301/pdf/fdb-info_4_Formulierungsbeispiele_fuer_informierte_Einwilligungen_2018_v2.1_A.pdf

Hinweis

Der [Arbeitskreis Medizinischer Ethik-Kommissionen in der Bundesrepublik Deutschland e.V.](#) stellt diverse Muster-texte und [Richtlinien](#) zur Verfügung.

Hinweis

In Kapitel [7.4](#) finden Sie das Beispiel einer informierten Einwilligung in einfachem [Markdown-Textformat](#).

5.2 Anonymisierung und Pseudonymisierung

Die [Begriffsbestimmungen in Art. 4 DSGVO](#) definieren Pseudonymisierung als “[...] die Verarbeitung personenbezogener Daten in einer Weise, dass die personenbezogenen Daten ohne Hinzuziehung zusätzlicher Informationen nicht mehr einer spezifischen betroffenen Person zugeordnet werden können, sofern diese zusätzlichen Informationen gesondert aufbewahrt werden und technischen und organisatorischen Maßnahmen unterliegen, die gewährleisten, dass die personenbezogenen Daten nicht einer identifizierten oder identifizierbaren natürlichen Person zugewiesen werden”. [§ 46 Abs. 5 Bundesdatenschutzgesetz \(BDSG\)](#) bestimmt Pseudonymisierung sehr ähnlich.

Gemäß [§ 3 \(6\) BDSG a.F.](#)³ ist Anonymisierung “[...] das Verändern personenbezogener Daten derart, dass die Einzelangaben über persönliche oder sachliche Verhältnisse nicht mehr oder nur mit einem unverhältnismäßig großen Aufwand an Zeit, Kosten und Arbeitskraft einer bestimmten oder bestimmbar natürlichen Person zugeordnet werden können”.

Für Gesundheitsdaten wird daher allgemein empfohlen:

- Entfernen direkter Identifikatoren (Name, Adresse etc.) oder Ersetzen durch Pseudonyme
- Besondere Berücksichtigung indirekter Identifikatoren (Alter, seltene Krankheit etc.)⁴

Für die konkrete Forschung mit Patienten oder Probanden ergibt sich der Bedarf, personenidentifizierende Daten von den Forschungsdaten separat zu verwalten und auf Verlangen der Probanden (z. B. bei Löschanfragen) wieder zusammenführen zu können.

Hinweis

In ihrem [Leitfaden zum Datenschutz in medizinischen Forschungsprojekten](#) stellt die TMF e.V. ein modularisiertes Datenschutzkonzept für den Forschungskontext bereit, siehe Pommerening u. a. (2014) und Abbildung [5.1](#). Zentrale Komponente ist dabei der Pseudonymisierungsdienst des Identitätsmanagement-Moduls. Ein Beispielspiel eines solchen Dienstes findet sich in Puchkovskiy & Gudenkauf (2015).

5.3 Kontrollierter Zugriff und Verteilung

Offene Repositories wie [GitHub](#) und [Zenodo](#) sind in der Regeln nicht geeignet für die Speicherung von Rohdaten.

Empfehlung: Stattdessen können Sie den Datenzugang wie folgt realisieren:

- Metadaten offen zugänglich machen

³In der Fassung der Bekanntmachung vom 14.01.2003 (BGBl. I S. 66), zuletzt geändert durch Gesetz vom 30.10.2017 (BGBl. I S. 3618) m.W.v. 09.11.2017, Außer Kraft getreten am 25.05.2018 aufgrund Gesetzes vom 30.06.2017 (BGBl. I S. 2097), siehe https://dejure.org/gesetze/BDSG_a.F.

⁴Die Angaben von Alter und seltener Krankheit kann die Reidentifizierung einzelner Personen ermöglichen.




Abbildung 5.1: Modularisiertes Datenschutzkonzept gemäß REF (eigene Darstellung).

- Die eigentlichen Forschungsrohdaten kontrolliert zugänglich machen
 - Auf separatem Antrag hin: Data Use Agreement (DUA)⁵
 - An definierter Kontaktstelle richtend

i Hinweis

In Kapitel 7.5 finden Sie das Beispiel eines Data Use Agreement in einfachem [Markdown-Textformat](#).

5.4 Verwendung standardisierter Terminologien

Die Verwendung einheitlicher Begriffe erhöht die Nutzbarkeit von Daten. Im Bereich Gesundheit gibt es definierte Standards, z. B.

- [ICD-10](#) (zur Codierung von Diagnosen)
- [SNOMED CT](#) (zur Codierung klinischer Begriffe)

Empfehlung: Dokumentieren Sie die Abbildung projektspezifischer Begriffe auf etablierte Terminologien in einer Mapping-Tabelle, sofern nötig.

5.5 Interoperabilität

Der Austausch von Daten zwischen verschiedenen Systemen erfordert Interoperabilität. Vermeiden Sie proprietäre Formate wie Microsoft Excel-Dateien mit undokumentierter Tabellenstruktur.

Empfehlung: Nutzen Sie auch hier etablierte Formate wie z. B. [HL7 FHIR](#).

⁵Siehe z. B. https://www.gesis.org/fileadmin/upload/dienstleistung/daten/secure_data_center/GESIS_Data_Use_Agreement_Off-Site.pdf

5.6 Versionierung und Nachvollziehbarkeit

Repositories wie [GitHub](#) zur Versionierung und [Zenodo](#) zur Datenveröffentlichung können Sie nicht für sensible Daten verwenden wohl aber für begleitende Datensätze:

- Ausführbare Skripte
- Dokumentation der Datenverarbeitungsschritte

Empfehlung: Verwenden Sie zur Versionierung der Datenbestände zusätzlich zu Semantic Versioning in Kapitel 4 logische Zusätze zur Beschaffenheit der Daten, z. B. v1.1.3-cleaned. Mögliche Zusätze sind:

- -raw für Rohdaten
- -cleaned für bereinigte oder aufbereitete Datenbestände
- -analysed für untersuchte oder um Analyseergebnisse ergänzte Datenbestände

Reine Ergänzungen sollten dabei weiterhin nur die MINOR-Nummer der Versionsnummer erhöhen, grundlegende strukturelle Änderungen (z. B. neue Variablenstruktur, neue Datensätze) die MAJOR-Nummer.

5.7 Dokumentation der Datenerhebung und der einzelnen Verarbeitungsschritte

Gegebenenfalls muss jede Änderung einer Variable bei der Datenerhebung dokumentiert werden, was den Aufwand zur Datenpflege und den Speicherbedarf schnell erhöht, siehe Abbildung 5.2.




Abbildung 5.2: Beispielrealisierung einer Änderungshistorie als UML-Klassendiagramm. Die Klassen könne als Tabellen verstanden werden, die Attribute als Spaltenbezeichnungen in den Tabellen.

Ebenfalls kann es notwendig werden, die Bedeutung der erhobenen Variablen in einem Codebuch zu dokumentieren, damit Rohdaten zu einem späteren Zeitpunkt und durch Dritte interpretiert werden können. Dazu gehören:

- Variablenbeschreibung: Name der Variable, Maßeinheit, Bedeutung
- Kodierung: Kodierung der Variablen z. B.

0: Weiblich
 1: Männlich
 2: Divers
 3: Ohne Angabe

Empfehlung: Klären Sie die Notwendigkeit zur Pflege einer Änderungshistorie und eines Codebuchs vor Projektbeginn.

6 Zusammenfassung

6.1 Anleitung zur Datenveröffentlichung

- **Plattformen:**
 - [Markdown](#) als Textauszeichnungssprache zur einfachen Dokumentation
 - [GitHub](#) für die Versionierung
 - [Zenodo](#) für DOI-Vergabe und Archivierung
- **Vorgehen:**
 1. Daten strukturieren
 2. GitHub-Repo erstellen
 3. Zenodo verknüpfen
 4. Release veröffentlichen
- **README:** Strukturierte Dokumentation der Daten und Nutzungshinweise

6.2 Datenmanagementplan (DMP) erstellen und pflegen

- **Metadaten:** Standardformate (z. B. [DataCite](#)), offene Formate ([CSV](#), [JSON](#))
- **Lizenz:** [CC-BY 4.0](#) oder [MIT-Lizenz](#) für die maximale Nachnutzung
- **FAIR-Prinzipien:** Daten auffindbar, zugänglich, interoperabel, und wiederverwendbar gestalten

6.3 Versionierung für Forschungsdaten anpassen

- **Semantic Versioning (SemVer):**
 - MAJOR . MINOR . PATCH für Änderungen
 - Änderungen dokumentieren in `CHANGELOG.md`
- **GitHub-Releases:** Neue Versionen in [GitHub](#) erzeugen automatisch neue DOIs in [Zenodo](#)

6.4 Umgang mit Gesundheitsdaten

- **Allgemeine Tipps:**
 - [Bände der TMF-Schriftenreihe](#) zu ausgewählten Themen
 - [Entscheidungshilfe](#) und [Richtlinien](#) des [Arbeitskreises Medizinischer Ethik-Kommissionen in der Bundesrepublik Deutschland e.V.](#)
- **Datenschutz und Ethik:**
 - [Ethikvotum](#)
 - Informierte Einwilligung
- **Anonymisierung und Pseudonymisierung:** [Leitfaden zum Datenschutz in medizinischen Forschungsprojekten](#)
- **Kontrollierter Zugriff und Verteilung:**
 - Keine Speicherung von Rohdaten in frei verfügbaren Repositories
 - Data Use Agreement (DUA)
- **Standardisierte Terminologien:** z. B. [ICD-10](#) und [SNOMED CT](#)
- **Interoperabilität:** Etablierte Formate wie z. B. [HL7 FHIR](#)
- **Versionierung:** [Semantic Versioning](#) ggf. durch logische Zusätze zur Beschaffenheit der Daten ergänzen, z. B. `v1.1.3-cleaned`
- **Dokumentation:** Notwendigkeit weiterer Dokumente vor Projektbeginn prüfen
 - Änderungshistorie
 - Codebuch

7 Anhang

7.1 README-Datei für GitHub-Repository: README.md

Project Name - Dataset

Overview

This repository contains the dataset used in the research article:

"Title of the Paper", published in *Journal Name*.

DOI of the article: [\[Link to Paper DOI\]](#)

Dataset Description

- **Raw Data**: `/raw_data/` contains the original data collected during the study.
- **Processed Data**: `/processed_data/` contains cleaned and analyzed data.
- **Scripts**: `/scripts/` includes scripts used for data analysis.

How to Use

1. Clone this repository: `git clone https://github.com/username/projectname-dataset.git`
2. Navigate through the folders for relevant files.
3. Refer to `metadata.txt` for detailed descriptions of the dataset and methodology.

Citation

If you use this dataset, please cite:

- **Dataset**: [\[DOI provided by Zenodo\]](#)
- **Paper**: [\[Paper DOI\]](#)

License

This dataset is licensed under [\[LICENSE NAME\]](#). See `LICENSE` file for details.

7.2 Datenmanagementplan: DMP.md

Datenmanagementplan (DMP)

1. Projektbeschreibung

Projektname: [\[Titel des Forschungsprojekts\]](#)

Verantwortliche*r Forschende*r: [\[Ihr Name\]](#)

Institution: [\[Name der Hochschule oder Forschungseinrichtung\]](#)

Förderorganisation (falls zutreffend): [\[Förderorganisation, z. B. DFG\]](#)

Ziel des Projekts

[Kurze Beschreibung des Projekts, z. B.:

"Dieses Projekt untersucht [Thema]. Die generierten Daten dienen als
↪ Grundlage für die Publikation im Journal [Name] und werden gemäß den
↪ FAIR-Prinzipien öffentlich zugänglich gemacht."]

2. Arten und Umfang der Daten

****Datentypen**:**

- [Primärdaten, z. B. experimentelle Messdaten, Umfrageergebnisse, Bilddaten]
- [Sekundärdaten, z. B. aus Literatur oder externen Datenquellen]
- [Metadaten, z. B. Dokumentation, Kontextbeschreibungen]

****Umfang der Daten**:**

- Geschätzte Dateigröße: [z. B. 500 MB]
- Anzahl der Dateien: [z. B. 30 CSV-Dateien]

****Dateiformate**:**

- Rohdaten: [z. B. CSV, TIFF]
- Analysedaten: [z. B. XLSX, JSON]
- Dokumentation: [z. B. Markdown, PDF]

3. Speicherung und Sicherung

****Speicherorte**:**

- ****Primäre Speicherung**:** GitHub-Repository ([Link hinzufügen])
- ****Backup-Strategie**:** Automatische Sicherung auf lokalen Systemen,
↪ Cloud-Diensten (z. B. [Google Drive, OneDrive]), o.a.

****Versionierung**:**

- Git wird zur Versionierung und Nachverfolgung von Änderungen verwendet.

****Zugriffsrechte während des Projekts**:**

- Nur Projektbeteiligte haben während der Erstellung Schreibrechte.
- GitHub ermöglicht eine öffentliche Einsicht nach Abschluss des Projekts.

4. Dokumentation und Metadaten

****Metadatenformat**:**

- [z. B. DataCite, Dublin Core]

****Beschreibung der Daten**:**

- Jede Datei wird durch eine README-Datei dokumentiert, die Informationen
↪ über:
 - Den Inhalt
 - Die Erhebungsmethodik
 - Verwendete Software oder Tools enthält.
- Schlagwörter: [Themenrelevante Begriffe, z. B. "Machine Learning",
↪ "Umweltdaten"]

****DOI-Zuweisung**:**

- Die Veröffentlichung erfolgt mit einem DOI über Zenodo.

5. Veröffentlichung und Nachnutzung

****Geplante Veröffentlichung**:**

- Veröffentlichung auf GitHub und Zenodo nach Akzeptanz des zugehörigen
↪ Papers.

****Lizenzierung**:**

- CC-BY 4.0 empfohlen für maximale Nachnutzung
- (Alternativen: CC-BY-NC 4.0, CC0, MIT-Lizenz)

****Zugänglichkeit**:**

- Die Daten sind über Zenodo öffentlich zugänglich (Open Access).
- Der DOI garantiert die dauerhafte Verfügbarkeit.
- Einschränkungen des Zugriffs werden über Embargo-Status Optionen von Zenodo
↪ geregelt.

****Interoperabilität**:**

- Daten werden in offenen Formaten gespeichert (siehe Abschnitt 2, Arten und
↪ Umfang der Daten)
- Metadaten-Standards: DataCite für Beschreibung und DOI-Referenzierung
- Ontologien oder kontrollierte Vokabulare zur Standardisierung von
↪ Begriffen: Verwendung von [z. B. MeSH, AGROVOC]

****Wiederverwendbarkeit**:**

- Lizenz: [z. B. MIT, erlaubt die Nachnutzung auch in proprietärer Software
↪ unter der Bedingung der Namensnennung]
- Vollständige Dokumentation der Daten: [Methoden, Kontext, verwendete
↪ Software wie z. B. Python-Skripte mit spezifischen Bibliotheksversionen]
- Anleitungen für die Nachnutzung: [z. B. siehe README-Datei]

****Langfristige Archivierung**:**

- Zenodo garantiert die Archivierung für mindestens 20 Jahre.

6. Verantwortlichkeiten und Ressourcen

****Datenverantwortliche/r**:**

- [Ihr Name]

****Zusätzliche Ressourcen**:**

- Genutzte Software: [z. B. Python, R]
- Infrastruktur: GitHub, Zenodo.

7. Ethik und Datenschutz

****Datenschutzanforderungen**:**

- Keine personenbezogenen Daten enthalten.
- Sensible Daten wurden entfernt oder anonymisiert.

****Ethikfreigaben**:**

- Nicht erforderlich. (Alternative: "Wurde durch die Ethikkommission
↪ genehmigt am [Datum].")

8. Aktualisierungen des Plans

****Versionierung des DMP**:**

- Initiale Version: [Datum]
- Geplante Überprüfung: [z. B. alle 6 Monate oder nach Projektmeilensteinen]

7.3 Datenmanagementplan für deutschsprachige Gesundheitsprojekte: DMP-health.md

Datenmanagementplan (DMP)

1. Projektübersicht

- Projekttitel:
- Institution:
- Kontakt:
- Förderer:

2. Datentypen

- Datentypen: (z. B. klinische Messdaten, Fragebögen, Bilddaten)
- Formate: (CSV, JSON, DICOM, etc.)
- Datenvolumen:

3. Ethik & Datenschutz

- Ethikvotum: (ja/nein, ID)
- Einwilligung: (ja/nein)
 - Nachnutzung:
- Rechtsgrundlage: (z. B. DSGVO Art. 6/9)
- Schutzbedarf:

4. Anonymisierung

- Methode:
 - [] anonymisiert
 - [] pseudonymisiert
- Schlüsselverwaltung:
- Re-Identifikationsrisiko geprüft: ja/nein
 - Prüfer:

5. Datenspeicherung & Sicherheit

- Speicherort(e):
- Zugriffskontrolle:
- Backup-Strategie:
- Verschlüsselung: ja/nein

6. Dokumentation & Metadaten

- Metadatenstandard:
- Codebuch vorhanden: ja/nein
- Variablenbeschreibung:

7. Standards & Interoperabilität

- Terminologien (z. B. ICD-10, SNOMED CT):
- Datenstandards (z. B. HL7 FHIR):

8. Versionierung

- Versionierungsmethode: (z. B. Semantic Versioning)
- Tools: (z. B. GitHub und Zenodo ohne sensible Daten, interne Dienste)
- Release-Strategie:

9. Datenzugang & Sharing

- Metadaten öffentlich: ja/nein
- Datenzugang:
 - [] offen
 - [] kontrolliert (DUA erforderlich)
- Kontakt für Zugang:

10. Langzeitarchivierung

- Repositories: (z. B. GitHub und Zenodo ohne sensible Daten, interne
↪ Dienste)
- Aufbewahrungsdauer:
- Löschkonzept:

11. Verantwortlichkeiten

- Datenverantwortliche:
- FDM-Support:

12. Rechtliches

- Verträge (DUA, Kooperationen):
- Einschränkungen:

7.4 Informierte Einwilligung: IC.md

Informierte Einwilligung zur Teilnahme an einer Studie

1. Projekttitle

- Titel:
- Institution:
- Verantwortliche Person:
- Kontakt:

2. Hintergrund und Ziel der Studie

[Kurze, verständliche Beschreibung des Zwecks der Studie.]

3. Ablauf der Teilnahme

[Kurze, verständliche Beschreibung des Ablaufs der Studie.]

- Dauer:
- Ort:

4. Risiken und Nutzen

- Mögliche Risiken:
- Erwarteter Nutzen:

5. Datenschutz

- Art der Daten: [z. B. Gesundheitsdaten]
- Verarbeitung: [pseudonymisiert | anonymisiert]

7 Anhang

- Speicherung:
- Zugriff:
- Weitergabe:

6. Freiwilligkeit

Die Teilnahme ist freiwillig und kann jederzeit ohne Angabe von Gründen beendet werden.

7. Widerruf

Ein Widerruf der Einwilligung ist jederzeit möglich.

- Kontakt:

8. Nutzung der Daten

[Kurze, verständliche Beschreibung des Datennutzung.]

- ☐ Zustimmung zur Nachnutzung für weitere Forschung
- ☐ Keine Nachnutzung

9. Veröffentlichung

Ergebnisse werden nur in aggregierter Form veröffentlicht.

10. Einwilligungserklärung

Ich habe die Informationen gelesen und verstanden und erkläre mich mit der Teilnahme einverstanden.

- Name:
- Datum:
- Unterschrift:

11. Kontakt für Rückfragen

- Name:
- E-Mail:
- Telefon:

7.5 Data Use Agreement: DUA.md

Data Use Agreement (DUA)

1. Parteien

****Datenbereitsteller (Provider):****

- Name:
- Institution:

- Kontakt:

****Datennutzende (Recipient):****

- Name:
- Institution:
- Kontakt:

2. Zweck der Datennutzung

Die Daten dürfen ausschließlich für folgenden Zweck verwendet werden:

- Projekt/Studie:
- Beschreibung:
- Laufzeit:

Eine Nutzung außerhalb dieses Zwecks ist nicht gestattet.

3. Beschreibung der Daten

- Datentypen:
- Sensitivität: [anonymisiert | pseudonymisiert]
- Enthaltene Variablen (kurz):
- Datenumfang:

4. Zugriffsrechte

- [] Zugriff nur für autorisierte Personen
- [] Weitergabe an Dritte: nicht erlaubt (Standard)

5. Datenschutz & Sicherheit

- [] Keine Re-Identifikation
- [] Sichere Speicherung
- [] Zugriffskontrolle und Verschlüsselung

6. Veröffentlichung

- [] Nur aggregierte Ergebnisse
- [] Keine Veröffentlichung von Rohdaten

7. Dokumentation

- [] Verarbeitungsschritte dokumentieren
- [] Versionierung

8. Laufzeit & Löschung

- Startdatum:
- Enddatum:
- Nach Ende: [löschen | zurückgeben | archivieren]

9. Verstöße

- [] Zugriff kann entzogen werden
- [] Rechtliche Schritte möglich

10. Rechtliches

- Anwendbares Recht:
- Gerichtsstand:

11. Unterschriften

- Provider: [Unterschrift]
- Recipient: [Unterschrift]

7.6 Checkliste der FAIR-Prinzipien: FAIR.md

FAIR-Checkliste für GitHub & Zenodo

Findable (Auffindbar)

- [] **F1**: Der Datensatz hat eine eindeutige und dauerhafte **DOI** (z. B. von Zenodo).
- [] **F2**: Metadaten enthalten einen klaren, beschreibenden **Titel** und **Schlüsselwörter**.
- [] **F3**: Der Datensatz ist in einem **offenen Repository** (GitHub & Zenodo) gespeichert.
- [] **F4**: Metadaten sind **durchsuchbar** (z. B. über Zenodo-Suchfunktionen).

Accessible (Zugänglich)

- [] **A1**: Der Datensatz ist über eine **öffentliche URL** abrufbar.
- [] **A1.1**: Daten und Metadaten sind auch nach Ablauf des Projekts verfügbar (Zenodo sichert dies).
- [] **A1.2**: **Metadaten bleiben abrufbar**, auch wenn die Daten entfernt wurden.
- [] **A2**: Falls Zugriffsbeschränkungen bestehen, sind diese klar dokumentiert.

Interoperable (Interoperabel)

- [] **I1**: Datensatz und Metadaten nutzen **offene, standardisierte Formate** (z. B. CSV, JSON, Markdown).
- [] **I2**: Metadaten enthalten **kontrollierte Vokabulare** oder **standardisierte Begriffe** (z. B. ORCID für Autoren).
- [] **I3**: Der Datensatz verlinkt relevante **Publikationen, Software oder andere Daten**.

Reusable (Nachnutzbar)

- [] **R1**: Metadaten enthalten eine **klare Lizenz** (z. B. CC-BY 4.0 oder
⇒ MIT für Code).
- [] **R1.1**: Der Datenmanagementplan (DMP) beschreibt den Datensatz
⇒ präzise.
- [] **R1.2**: Der Datensatz enthält eine detaillierte **README.md** zur
⇒ Nutzung.
- [] **R1.3**: Die Datenquelle, Entstehung und Verarbeitungsschritte sind
⇒ dokumentiert (z. B. in der README oder im DMP).

Tipp: Halte die README.md und Metadaten aktuell, um die FAIR-Prinzipien
⇒ langfristig zu gewährleisten.

7.7 Beispiel für ein Changelog: CHANGELOG.md

Legen Sie die Datei CHANGELOG.md auf derselben Orderebene wie README.md an:

Changelog

v1.1.0 - 2025-01-10

- Hinzugefügt: Neue Datenpunkte für [Experiment XYZ].
- Geändert: Erweiterung der README mit zusätzlichen Analyseschritten.

v1.0.1 - 2024-12-20

- Behoben: Fehler in den Variablenbeschreibungen.

v1.0.0 - 2024-12-01

- Initiale Veröffentlichung des Datensatzes.

7.8 Beispiele für Metadaten mit Zenodo

Beispiel: Metadaten dieses Dokuments in der Version 1.0.3 als [DataCite JSON](#) generiert von Zenodo:

```
{
  "creators": [
    {
      "familyName": "sgudenkauf",
      "name": "sgudenkauf",
      "nameIdentifiers": [],
      "nameType": "Personal"
    }
  ],
  "dates": [
    {
      "date": "2025-02-10",
      "dateType": "Issued"
    },
    {
```

```

    "date": "2025-02-10",
    "dateType": "Updated"
  },
],
"descriptions": [
  {
    "description": "Updated Acknowledgments.",
    "descriptionType": "Abstract"
  }
],
"identifiers": [
  {
    "identifier": "https://zenodo.org/records/14843008",
    "identifierType": "URL"
  },
  {
    "identifier": "10.5281/zenodo.14843008",
    "identifierType": "DOI"
  },
  {
    "identifier": "oai:zenodo.org:14843008",
    "identifierType": "oai"
  }
],
"publicationYear": "2025",
"publisher": "Zenodo",
"relatedIdentifiers": [
  {
    "relatedIdentifier": "https://github.com/sgudenkauf/quarto-simple-rdm-
      ↪ tutorial/tree/v1.0.3",
    "relatedIdentifierType": "URL",
    "relationType": "IsSupplementTo",
    "resourceTypeGeneral": "Software"
  },
  {
    "relatedIdentifier": "10.5281/zenodo.14840823",
    "relatedIdentifierType": "DOI",
    "relationType": "IsVersionOf"
  },
  {
    "relatedIdentifier": "https://archive.softwareheritage.org/swh:1:dir:f
      ↪ b7dfefa8b9645de237e4eb431fb42c4c331c570;origin=https://doi.org/10
      ↪ .5281/zenodo.14840823;visit=swh:1:snp:e214173932653196d0d9994894a
      ↪ e4045823a443c;anchor=swh:1:rel:02f5937d89e2a1bb94faaf03a5135308a8
      ↪ 13b4ce;path=sgudenkauf-quarto-simple-rdm-tutorial-2258c18",
    "relatedIdentifierType": "URL",
    "relationType": "IsIdenticalTo"
  }
],
"rightsList": [
  {
    "rights": "MIT License",

```



```

    "rightsIdentifier": "mit",
    "rightsIdentifierScheme": "spdx",
    "rightsUri": "https://opensource.org/licenses/MIT"
  },
],
"schemaVersion": "http://datacite.org/schema/kernel-4",
"titles": [
  {
    "title": "sgudenkauf/quarto-simple-rdm-tutorial: v1.0.3"
  }
],
"types": {
  "resourceType": "",
  "resourceTypeGeneral": "Software"
},
"version": "v1.0.3"
}

```

Beispiel: Metadaten dieses Dokuments in der Version 1.0.3 als [Dublin Core XML](#) generiert von Zenodo:

```

<?xml version='1.0' encoding='utf-8'?>
<oai_dc:dc xmlns:dc="http://purl.org/dc/elements/1.1/"
  ↪ xmlns:oai_dc="http://www.openarchives.org/OAI/2.0/oai_dc/"
  ↪ xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"
  ↪ xsi:schemaLocation="http://www.openarchives.org/OAI/2.0/oai_dc/
  ↪ http://www.openarchives.org/OAI/2.0/oai_dc.xsd">
  <dc:creator>sgudenkauf</dc:creator>
  <dc:date>2025-02-10</dc:date>
  <dc:description>&lt;p&gt;Updated
  ↪ Acknowledgments.&lt;p&gt;</dc:description>
  <dc:identifier>https://doi.org/10.5281/zenodo.14843008</dc:identifier>
  <dc:identifier>oai:zenodo.org:14843008</dc:identifier>
  <dc:publisher>Zenodo</dc:publisher>
  <dc:relation>https://github.com/sgudenkauf/quarto-simple-rdm-tutorial/tree
  ↪ e/v1.0.3</dc:relation>
  <dc:relation>https://doi.org/10.5281/zenodo.14840823</dc:relation>
  <dc:rights>info:eu-repo/semantics/openAccess</dc:rights>
  <dc:rights>MIT License</dc:rights>
  <dc:rights>https://opensource.org/licenses/MIT</dc:rights>
  <dc:title>sgudenkauf/quarto-simple-rdm-tutorial: v1.0.3</dc:title>
  <dc:type>info:eu-repo/semantics/other</dc:type>
</oai_dc:dc>

```

7.9 Verwendete Softwarewerkzeuge

Zur Erstellung dieses Leitfadens haben wir verschiedene Softwarewerkzeuge verwendet. Deren Gebrauch dokumentieren wir gemäß Baresel u. a. (2024). Genannt werden der Name des Werkzeugs, Quelle, Verwendungszweck und Anwendungsbereich.¹ Die Angaben sollten den [Empfehlungen](#) des APA-Stils für die Angabe von Softwareversionen entsprechen.

¹Wir verzichten auf die zusätzliche Nennung der "genutzten Funktion" gemäß Baresel u. a. (2024), da sie sich aus unserer Sicht mit dem Verwendungszweck doppelt. Siehe auch Tabelle 2 in Baresel u. a. (2024).

1. OpenAI. (2023). **ChatGPT** (Version 14. März) [Großes Sprachmodell]. <https://chat.openai.com>²
 - Übersetzung deutsch/englisch (Abstract)
 - Generieren von Vorschlägen für Markdown-Vorlagen (Anhang, Kapitel 3)
 - Generieren von Vorschlägen zu Vorgehen und Struktur (gesamtes Dokument)
2. Microsoft Corporation. (2024). **Visual Studio Code** (Version 1.96.2) [Quelltext-Editor]. <https://code.visualstudio.com>
 - Editor zum Schreiben der Quelldateien (gesamtes Projekt)
3. Posit, PBC. (2024). **Quarto** (Version 1.118.0) [Dokumentations- und Publishing-Software]. <https://quarto.org>
 - Übersetzen der Quelldateien in Webseite und PDF-Dokument, siehe Verzeichnis docs/ (gesamtes Projekt)
4. Posit, PBC. (2024). **Quarto Extension for Visual Studio Code** (Version 1.6.39) [Software-Erweiterung]. <https://quarto.org/docs/tools/vscode.html>
 - Komfortable Bedienung von Quarto aus Visual Studio Code heraus (gesamtes Projekt)
 - Quarto-Syntaxunterstützung (gesamtes Projekt)

²Die genaue Versionsnummer von ChatGPT ist nicht öffentlich zugänglich. Wir verwenden daher das Datum der letzten Aktualisierung als Versionsbezeichnung.

Literaturverzeichnis

[Data models to GO-FAIR](#). In: Nature Genetics Bd. 49 (2017), Nr. 7, S. 971–971

[DOI Handbook](#), 2023

Bals, Fred: [Top open source licenses and legal risk for developers](#), 2024

Baresel, Kira ; Eube, Cornelia ; Knorr, Dagmar ; Lutter, Ly ; Nys, Jasmin de ; Röben, Marieke: [KI-Gebrauch im Studienkontext dokumentieren](#) (2024), S. 304839 b. – Artwork Size: 304839 b Medium: application/pdf Publisher: Medien- und Informationszentrum, Leuphana Universität Lüneburg Version Number: 1

Basili, Victor R. ; Caldiera, Gianluigi ; Rombach, H. Dieter: [Goal Question Metric Paradigm](#). In: Encyclopedia of Software Engineering - 2 Volume Set : John Wiley & Sons, Inc., 1994 – ISBN \#1-54004-8, S. 528–532

Charollais, Patrick: ECMA-404, 2nd edition, December 2017

Hausenblas, M. ; Wilde, E. ; Tennison, J.: [URI Fragment Identifiers for the text/csv Media Type](#) (Nr. RFC7111) : RFC Editor, 2014

Malinowski, Christine: [File Naming Best Practices](#) : MASSACHUSETTS INSTITUTE OF TECHNOLOGY, 2020

Pommerening, Klaus ; Drepper, Johannes ; Helbing, Krister ; Ganslandt, Thomas: [Leitfaden zum Datenschutz in medizinischen Forschungsprojekten: Generische Lösungen der TMF 2.0](#) : Medizinisch Wissenschaftliche Verlagsgesellschaft, 2014 – ISBN 978-3-95466-295-1

Puchkovskiy, Alexandr ; Gudenkauf, Stefan: [Service-basiertes High-Performance Privacy Preserving Record Linkage für die Epidemiologische Datenauswertung](#). In: 60. Jahrestagung der Deutschen Gesellschaft für Medizinische Informatik, Biometrie und Epidemiologie e. V. (GMDS 2015). Krefeld, 2015

Wilkinson, Mark D. ; Dumontier, Michel ; Aalbersberg, IJsbrand Jan ; Appleton, Gabrielle ; Axton, Myles ; Baak, Arie ; Blomberg, Niklas ; Boiten, Jan-Willem ; u. a.: [The FAIR Guiding Principles for scientific data management and stewardship](#). In: Scientific Data Bd. 3 (2016), Nr. 1, S. 160018

